

T.C.
GÜMÜŞHANE ÜNİVERSİTESİ
GÜMÜŞHANE MESLEK YÜKSEKOKULU
BİLGİSAYAR TEKNOLOJİLERİ BÖLÜMÜ
BİLGİSAYAR PROGRAMCILIĞI PROGRAMI



FINAL ÖDEV-2
CV – İLAN EŞLEŞMESİ

Word2Vec Tabanlı Metin Benzerliği Hesaplama ve Değerlendirme

*Proje [50]: İnsan Kaynakları – Aday CV'leri ile İş İlanlarının
Metinsel Uyumunun Ölçülmesi*

PROJE EKİBİ:

1. Mario Enrique Motede Dasilva | 2411081503
2. Heriberto Fernandez Chale | 2411081509
3. Matias Fernando Ndong Owono Obiang | 2311081634

Ders: Doğal Dil İşleme

Öğretim Elemanı: Dr. Rabia Yaşa Koştaş

GitHub: <https://github.com/herfech/CV-ilan-eslesmesi.git>

2025–2026 Bahar Dönemi

İçindekiler

1 Giriş	2
1.1 Ödevin Amacı	2
1.2 Veri Seti	2
1.3 Ham Veri vs Ön İşlenmiş Veri Karşılaştırması	2
1.4 GitHub Reposu	2
2 Yöntem	2
2.1 Word2Vec Vektörleştirme Detayları	2
2.2 Vektör Çıktıları — Her Model için En Benzer 5 Kelime	3
2.3 Örnek Giriş Metni	4
2.4 Benzerlik Hesaplama Yöntemi	4
3 Sonuçlar ve Değerlendirme	5
3.1 Değerlendirme-1: Cosine Benzerlik Tablosu	5
3.2 Değerlendirme-2: Anlamsal Değerlendirme	6
3.3 Değerlendirme-3: Jaccard Sıralama Tutarlılığı	6
3.4 Model Yapılandırmalarının Etkisi	8
4 Sonuç ve Öneriler	8
4.1 Genel Çıkarımlar	8
4.2 Hangi Model Hangi Görev İçin?	9
4.3 Gelecek Çalışmalar	9
Ekler	9

1 Giriş

1.1 Ödevin Amacı

Bu ödevin amacı, CV–İlan Eşleşmesi projesine ait veri seti üzerinde Word2Vec modelleri eğiterek metinler arası benzerlik hesaplamaları yapmak ve modellerin karşılaştırmalı başarımını değerlendirmektir. Ödev-1’de gerçekleştirilen metin ön işleme adımlarının çıktıları (lemmatized ve stemmed veri setleri) bu ödevde girdi olarak kullanılmıştır.

1.2 Veri Seti

CV–İlan Eşleşmesi Veri Seti

Kaynak	Proje[50] kapsamında özgün olarak oluşturulmuştur(<code>create_dataset.py</code>)
Toplam belge	280
CV sayısı	250 (10 kategori, 25’er belge)
İş ilanı	30 (10 kategori, 3’er seviye: Junior/Mid/Senior)
Kategoriler	Data Science, Software Engineering, Marketing, Finance, HR, Healthcare, Education, Sales, Project Management, Cybersecurity
Format	<code>document_id content</code>

1.3 Ham Veri vs Ön İşlenmiş Veri Karşılaştırması

Tablo 1: Ham Veri ve Ön İşlenmiş Veri Yapısal Karşılaştırması

Özellik	Ham Veri	Lemmatized	Stemmed
Belge sayısı	280	280	280
Ort. kelime/belge	≈105	≈68	≈65
Stopword	Var	Yok	Yok
Büyük/küçük harf	Karma	Küçük	Küçük
Kelime formu	Orijinal	Sözlük kökü	Kök/gövde
Dosya	<code>cv_jobs_raw.csv</code>	<code>lemmatized.csv</code>	<code>stemmed.csv</code>

1.4 GitHub Reposu

Tüm kodlar, modeller ve veri setleri GitHub reposunda mevcuttur:

<https://github.com/herfech/CV-ilan-eslesmesi>

2 Yöntem

2.1 Word2Vec Vektörleştirme Detayları

Gensim kutuphanesi kullanılarak aşağıdaki 8 parametre seti ile hem lemmatized hem de stemmed veri setleri için toplamda **16 Word2Vec modeli** eğitilmiştir. Ortak parametreler: `min_count=2`, `epochs=10`, `workers=4`, `seed=42`.

Tablo 2: Word2Vec Model Parametreleri ve Tam Adlari

No	Veri Seti	Model Tipi	Window	Dim	Model Adı
1	lemmatized	CBOW	2	100	word2vec_lem_cbow_win2_dim100
2	lemmatized	Skip-gram	2	100	word2vec_lem_skipgram_win2_dim100
3	lemmatized	CBOW	4	100	word2vec_lem_cbow_win4_dim100
4	lemmatized	Skip-gram	4	100	word2vec_lem_skipgram_win4_dim100
5	lemmatized	CBOW	2	300	word2vec_lem_cbow_win2_dim300
6	lemmatized	Skip-gram	2	300	word2vec_lem_skipgram_win2_dim300
7	lemmatized	CBOW	4	300	word2vec_lem_cbow_win4_dim300
8	lemmatized	Skip-gram	4	300	word2vec_lem_skipgram_win4_dim300
9	stemmed	CBOW	2	100	word2vec_stem_cbow_win2_dim100
10	stemmed	Skip-gram	2	100	word2vec_stem_skipgram_win2_dim100
11	stemmed	CBOW	4	100	word2vec_stem_cbow_win4_dim100
12	stemmed	Skip-gram	4	100	word2vec_stem_skipgram_win4_dim100
13	stemmed	CBOW	2	300	word2vec_stem_cbow_win2_dim300
14	stemmed	Skip-gram	2	300	word2vec_stem_skipgram_win2_dim300
15	stemmed	CBOW	4	300	word2vec_stem_cbow_win4_dim300
16	stemmed	Skip-gram	4	300	word2vec_stem_skipgram_win4_dim300

2.2 Vektör Çıktıları — Her Model için En Benzer 5 Kelime

Her model için "develop" anahtar kelimesi seçilerek vektör uzayındaki en yakın 5 kelime sunulmuştur. Amac, modelden modele benzerlik skorlarının nasıl değiştiğini göstermektir. Bu skorlar tek başına modelin başarısını göstermek için yetersizdir.

Tablo 3: 16 Model için Vektör Çıktıları — “develop” Kelimesi

Model Adı	En Benzer 5 Kelime	Maks. Skor
lem_cbow_win2_dim100	skill, design, implement, create, build	0.91
lem_skipgram_win2_dim100	implement, build, create, deploy, maintain	0.89
lem_cbow_win4_dim100	implement, design, build, create, deploy	0.92
lem_skipgram_win4_dim100	implement, build, deploy, create, design	0.90
lem_cbow_win2_dim300	implement, build, design, create, deploy	0.93
lem_skipgram_win2_dim300	implement, build, deploy, maintain, create	0.91
lem_cbow_win4_dim300	implement, build, design, create, deploy	0.94
lem_skipgram_win4_dim300	implement, build, deploy, create, maintain	0.93
stem_cbow_win2_dim100	skill, design, implement, creat, build	0.90
stem_skipgram_win2_dim100	implement, build, creat, deploy, maintain	0.88
stem_cbow_win4_dim100	implement, design, build, creat, deploy	0.91
stem_skipgram_win4_dim100	implement, build, deploy, creat, design	0.89
stem_cbow_win2_dim300	implement, build, design, creat, deploy	0.92
stem_skipgram_win2_dim300	implement, build, deploy, maintain, creat	0.90
stem_cbow_win4_dim300	implement, build, design, creat, deploy	0.93
stem_skipgram_win4_dim300	implement, build, deploy, creat, maintain	0.92

Gözlem: dim=300 modellerinin maks. skoru dim=100 modellerine göre genel olarak daha yüksektir. Stemmed modellerde “create” yerine “creat”, “build” yerine bazı durumlarda

“build” kalir — koke indirgeme anlamsal bilgiyi kismen kaybettirir. Hangi modelin daha basarili olmasini bekliyoruz? Skip-gram + window=4 + dim=300 kombinasyonu: Skip-gram nadir kelimelerin vektorlerini daha iyi ogrenirken genis pencere daha zengin baglamsal iliskiler saglar ve yuksek boyut daha ayirt edici semantik uzaylar olusturur.

2.3 Ornek Giris Metni

Asagidaki metin, veri setinden (`cv_jobs_dataset.csv`) secilmis olup disaridan alinmamistir.

Document ID: cv_001 **Kategori:** Data Science

Isabella Wilson principal professional with 18 years experience in data science field. SKILLS AND EXPERTISE: python machine learning deep learning neural networks tensorflow pytorch scikit-learn pandas numpy data analysis statistical modeling regression classification clustering natural language processing computer vision data visualization matplotlib seaborn sql database big data spark hadoop feature engineering model deployment mlops statistical analysis predictive modeling data mining exploratory data analysis hypothesis testing ab testing time series forecasting business intelligence tableau power bi r programming data warehousing etl pipeline cloud computing aws gcp azure jupyter notebook git version control. PROFESSIONAL EXPERIENCE: developed machine learning models to predict customer churn reducing attrition by 25 percent built recommendation system increasing user engagement by 40 percent created automated data pipeline processing 10 million records daily. EDUCATION: master degree data science machine learning artificial intelligence university. PROFESSIONAL SUMMARY: results driven Data Science professional with 18 years of progressive experience.

2.4 Benzerlik Hesaplama Yontemi

Her model icin benzerlik asagidaki adimlarla hesaplanmistir:

1. Giris metni ve karsilastirilacak belge tokenize edilir
2. Her token icin Word2Vec modelinden vektor alinir; modelde olmayan kelimeler atlanir
3. Tum token vektorlerinin aritmetik ortalamasi alinir (belge vektörü)
4. Eger hic token vektörü yoksa Sifir Vektörü (Zero Vector) atanir — NaN/ZeroDivisionError’u onler
5. Giris metni ile her belge arasinda Kosinus Benzerligi hesaplanir
6. Her model icin en yuksek skora sahip Top-5 belge secilir

$$\cos(\theta) = \frac{\mathbf{A} \cdot \mathbf{B}}{\|\mathbf{A}\| \cdot \|\mathbf{B}\|} \quad (1)$$

Listing 1: Belge Vektörü + Zero Vector Savunma Mekanizması

```

1 def doc_vector(text, model):
2     tokens = preprocess(text)
3     vecs = [model.wv[w] for w in tokens if w in model.wv]
4     if not vecs:                                     # Hic vektor yoksa
5         return np.zeros(model.vector_size) # Zero Vector
6     return np.mean(vecs, axis=0)

```

3 Sonuçlar ve Değerlendirme

3.1 Değerlendirme-1: Cosine Benzerlik Tablosu

Giris metnine (cv_001) en benzer 5 belge her model için cosine benzerliği ile bulunmuştur. Toplam: 16 model $\times$ 5 belge = 80 sonuc.

Tablo 4: Her Model için Top-5 Benzer Belge ve Cosine Skorları (Tam Veri Seti)

Model Adı	5 Benzer Belge	Cosine Skorları	Ort.
lem_cbow_win2_dim300	cv_136, cv_234, cv_004, cv_074, cv_154	[1.0, 1.0, 1.0, 1.0, 1.0]	0.9999
lem_cbow_win4_dim300	cv_234, cv_136, cv_226, cv_096, cv_154	[1.0, 1.0, 1.0, 1.0, 1.0]	0.9998
stem_cbow_win2_dim300	cv_011, cv_121, cv_044, cv_074, cv_004	[1.0, 1.0, 1.0, 1.0, 1.0]	0.9998
lem_cbow_win2_dim100	cv_136, cv_234, cv_096, cv_146, cv_226	[1.0, 1.0, 1.0, 1.0, 1.0]	0.9997
stem_cbow_win2_dim100	cv_011, cv_121, cv_073, cv_100, cv_211	[1.0, 1.0, 1.0, 1.0, 1.0]	0.9997
stem_cbow_win4_dim300	cv_011, cv_073, cv_121, cv_154, cv_234	[1.0, 1.0, 1.0, 1.0, 1.0]	0.9997
lem_cbow_win4_dim100	cv_136, cv_096, cv_226, cv_196, cv_176	[1.0, 1.0, 1.0, 1.0, 1.0]	0.9996
stem_cbow_win4_dim100	cv_011, cv_121, cv_073, cv_211, cv_234	[1.0, 1.0, 1.0, 0.999, 0.999]	0.9995
stem_skipgram_win2_dim300	cv_011, cv_121, cv_211, cv_131, cv_061	[1.0, 0.999, 0.999, 0.997, 0.996]	0.9983
lem_skipgram_win2_dim300	cv_121, cv_011, cv_211, cv_172, cv_140	[0.999, 0.999, 0.999, 0.997, 0.997]	0.9980
stem_skipgram_win2_dim100	cv_011, cv_121, cv_211, cv_131, cv_061	[1.0, 1.0, 0.999, 0.996, 0.995]	0.9978
lem_skipgram_win2_dim100	cv_121, cv_011, cv_211, cv_172, cv_031	[0.999, 0.999, 0.999, 0.996, 0.995]	0.9975
stem_skipgram_win4_dim300	cv_011, cv_121, cv_211, cv_031, cv_201	[0.999, 0.999, 0.999, 0.992, 0.99]	0.9957
lem_skipgram_win4_dim300	cv_011, cv_121, cv_211, cv_031, cv_061	[0.999, 0.999, 0.999, 0.992, 0.989]	0.9956
stem_skipgram_win4_dim100	cv_011, cv_121, cv_211, cv_031, cv_201	[0.999, 0.999, 0.998, 0.991, 0.989]	0.9952
lem_skipgram_win4_dim100	cv_011, cv_121, cv_211, cv_031, cv_201	[0.999, 0.999, 0.999, 0.993, 0.987]	0.9951

3.2 Değerlendirme-2: Anlamsal Değerlendirme

Her modelin önerdiği 5 benzer belge için 1–5 arası anlamsal benzerlik puanı **elle verilmistir** (YZ kullanılmamıştır). Giriş metni Data Science CV’sidir; aynı kategorideki belgeler yüksek puan almıştır.

Puanlama Kriteri:

- **5 puan:** Neredeyse aynı temada, çok güçlü benzerlik
- **4 puan:** Anlamlı, açık benzerlik içeriyor
- **3 puan:** Ortalama düzeyde benzer
- **2 puan:** Kısmen ilgili ama bağlamı tutmuyor
- **1 puan:** Çok alakasız, anlamca zayıf benzerlik

Tablo 5: 16 Model — Anlamsal Değerlendirme Puanları (Elle Verilmistir)

Model Adı	5 Benzer Belge	Puanlar (1–5)	Ort.
lem_cbow_win2_dim300	cv_136, cv_234, cv_004, cv_074, cv_154	5, 5, 4, 4, 4	4.4
lem_cbow_win4_dim300	cv_234, cv_136, cv_226, cv_096, cv_154	5, 5, 4, 4, 3	4.2
stem_cbow_win2_dim300	cv_011, cv_121, cv_044, cv_074, cv_004	5, 5, 4, 4, 4	4.4
lem_cbow_win2_dim100	cv_136, cv_234, cv_096, cv_146, cv_226	5, 5, 4, 4, 4	4.4
stem_cbow_win2_dim100	cv_011, cv_121, cv_073, cv_100, cv_211	5, 5, 4, 3, 3	4.0
stem_cbow_win4_dim300	cv_011, cv_073, cv_121, cv_154, cv_234	5, 4, 5, 4, 3	4.2
lem_cbow_win4_dim100	cv_136, cv_096, cv_226, cv_196, cv_176	5, 5, 4, 4, 4	4.4
stem_cbow_win4_dim100	cv_011, cv_121, cv_073, cv_211, cv_234	5, 5, 4, 3, 3	4.0
stem_skipgram_win2_dim300	cv_011, cv_121, cv_211, cv_131, cv_061	5, 5, 4, 3, 3	4.0
lem_skipgram_win2_dim300	cv_121, cv_011, cv_211, cv_172, cv_140	5, 5, 4, 3, 3	4.0
stem_skipgram_win2_dim100	cv_011, cv_121, cv_211, cv_131, cv_061	5, 5, 4, 3, 3	4.0
lem_skipgram_win2_dim100	cv_121, cv_011, cv_211, cv_172, cv_031	5, 5, 4, 3, 2	3.8
stem_skipgram_win4_dim300	cv_011, cv_121, cv_211, cv_031, cv_201	5, 5, 4, 3, 3	4.0
lem_skipgram_win4_dim300	cv_011, cv_121, cv_211, cv_031, cv_061	5, 5, 4, 3, 3	4.0
stem_skipgram_win4_dim100	cv_011, cv_121, cv_211, cv_031, cv_201	5, 5, 4, 3, 3	4.0
lem_skipgram_win4_dim100	cv_011, cv_121, cv_211, cv_031, cv_201	5, 5, 4, 3, 2	3.8


Yorum: Neredeyse tüm modeller yüksek anlamsal puan almıştır (3.8–4.4). Bunun temel nedeni, giriş metninin Data Science kategorisinden olması ve modellerin coğunluğunun aynı kategoriden belgeler önermesidir. CBOW modellerinin anlamsal puanları Skip-gram modellerine kıyasla biraz daha yüksek çıkabilmistir — bu paradoks, CBOW’un sık geçen Data Science kelimelerini daha iyi yakalamasından kaynaklanmaktadır. Hangi modeller daha yüksek ortalama aldı? Genel olarak **dim300** ve geniş bağlamli (**win4**) modeller; ancak bu veri seti için farklar oldukça küçüktür.

3.3 Değerlendirme-3: Jaccard Sıralama Tutarlılığı

$$\text{Jaccard}(A, B) = \frac{|A \cap B|}{|A \cup B|}$$

İki farklı modelin aynı giriş metnine verdiği Top-5 sonuçlar arasındaki örtüşmeyi ölçer. Tekil bir başarı ölçmüştür; hangi modellerin birbirine benzer sonuçlar ürettiği gösterilir.

16×16 Jaccard matrisi `data/jaccard_matrix.csv` dosyasında mevcuttur.



Şekil 1: Jaccard Benzerlik Matrisi Heatmap (16×16) — Modellerin Top-5 Sonuç Ortusme Oranı. Kosegen her zaman 1.00'dir (modelin kendisiyle karşılaştırması); yorumlamada hesaba katılmaz.

Temel bulgular:

- Aynı veri seti (lemmatized veya stemmed) ve benzer hiperparametrelili modeller yüksek Jaccard skoru üretmiştir
- CBOW modelleri kendi aralarında, Skip-gram modelleri kendi aralarında daha yüksek ortusme göstermiştir — mimari benzerlik sıralama tutarlılığını belirleyen temel faktördür
- window=4 modelleri, window=2 modellerine kıyasla birbirleriyle daha fazla orusen sonuçlar üretmiştir
- Lemmatized ve stemmed veri setleri arasındaki modeller görece düşük Jaccard skoru üretmiştir; on işleme yöntemi model çıktılarına önemli ölçüde etkilemektedir
- CBOW + dim300 grubu en tutarlı iç grup oluşturmaktadır

3.4 Model Yapilandirmalarının Etkisi

Tablo 6: Hiperparametre Etkisi Özeti

Parametre	Gözlem
CBOW vs Skip-gram	Skip-gram modelleri, özellikle küçük-orta veri setlerinde bağlamsal ilişkileri daha zengin öğrenirken bu veri setinde CBOW modelleri daha yüksek cosine skorları üretmiştir.
Window boyutu (2 vs 4)	Window=4 modelleri daha geniş bağlamdan faydalanarak kavramsal ilişkileri daha iyi öğrenmiş, Jaccard matrisinde daha tutarlı sonuçlar üretmiştir.
Vektör boyutu (100 vs 300)	dim=300 modelleri semantik özellikleri daha iyi yakalamıştır; ancak eğitim süresi dim=100'e kıyasla 2x uzamıştır.
Lemmatized vs Stemmed	Her iki ön işleme yöntemi de yüksek cosine skoru üretmiştir. Stemming bazı kelimeleri küçültmekte (“create” → “creat”) ve anlam kaybına yol açabilmektedir.

4 Sonuç ve Öneriler

4.1 Genel Çıkarımlar

Bu ödevde CV–İlan Eşleşmesi projesine ait 280 belgeden oluşan veri seti üzerinde 16 farklı Word2Vec modeli eğitilmiş ve 3 farklı değerlendirme yöntemi uygulanmıştır.

En başarılı modeller (cosine ortalama):

1. word2vec_lemmatized_cbow_win2_dim300 — Ortalama cosine: 0.9999
2. word2vec_lemmatized_cbow_win4_dim300 — Ortalama cosine: 0.9998
3. word2vec_stemmed_cbow_win2_dim300 — Ortalama cosine: 0.9998

En yüksek anlamsal puan:

- lem_cbow_win2_dim300, lem_cbow_win2_dim100, lem_cbow_win4_dim100, stem_cbow_win2_dim300 — Ortalama anlamsal puan: 4.4

En düşük başarılı model:

- word2vec_lemmatized_skipgram_win4_dim100 ve word2vec_stemmed_skipgram_win4_dim100 — Anlamsal ortalama: 3.8

4.2 Hangi Model Hangi Görev İçin?

Tablo 7: Görev Bazında Model Önerileri

Görev	Önerilen Model
Hızlı ön eleme (büyük veri)	CBOW + window2 + dim100
Semantik doğruluk	Skip-gram + window4 + dim300
Denge (hız + doğruluk)	Skip-gram + window2 + dim100
Üretim ortamı	TF-IDF ön eleme + Word2Vec son sıralama

4.3 Gelecek Çalışmalar

1. **BERT / Sentence-Transformers:** Bağlam duyarlı modeller daha iyi anlam temsili sağlar
2. **Daha büyük veri seti:** Gerçek CV ve iş ilanı verileriyle modelleri yeniden eğitmek
3. **ATS Entegrasyonu:** Greenhouse, Workable, BambooHR API bağlantısı
4. **PDF Desteği:** pdfplumber ile gerçek CV dosyalarını okuma
5. **Streamlit Cloud:** Uygulamayı halka açık URL ile yayınlamak

Ekler

A. Proje Dosya Yapısı

Listing 2: GitHub Repo Yapısı

```

1 CV-ilan-eslesmesi/
2 |-- app.py                # Streamlit dashboard
3 |-- matching_engine.py    # TF-IDF + Cosine Similarity
   motoru
4 |-- sample_data.py        # 5 örnek CV ve iş ilanı
5 |-- create_dataset.py     # 280 belgeli veri seti olusturucu
6 |-- test_matching.py      # Terminal testi
7 |-- Final_0dev2.ipynb     # 0dev-2 ana notebook (Word2Vec)
8 |-- data/
9 |   |-- cv_jobs_raw.csv    # Ham veri seti (280 belge)
10 |   |-- lemmatized.csv    # On islenmis (lemmatization)
11 |   |-- stemmed.csv       # On islenmis (stemming)
12 |   |-- cosine_evaluation.csv # Cosine degerlendirme sonuclari
13 |   |-- jaccard_matrix.csv # 16x16 Jaccard matrisi
14 |-- models/               # 16 Word2Vec modeli (.model)
15 |-- plots/                # Grafik ciktilari (.png)
16 |-- notebooks/plots
17 |   |-- 01_eda_ve_onisleme.ipynb
18 |   |-- 02_model_karsilastirma.ipynb
19 |-- rapor/

```

```
20 |-- cv_ilan_eslesme_rapor.tex
21 |-- cv_ilan_eslesme_rapor.pdf
22 |-- GU_LOGO.png
23 |-- 04_jaccard_heatmap.png
```

B. Gereksinimler

Listing 3: requirements.txt

```
1 streamlit>=1.35.0
2 scikit-learn>=1.4.0
3 pandas>=2.0.0
4 plotly>=5.18.0
5 nltk>=3.8.0
6 numpy>=1.26.0
7 gensim>=4.3.0
8 pdfplumber>=0.10.0
9 matplotlib>=3.8.0
10 seaborn>=0.13.0
11 jupyter>=1.0.0
12 ipykernel>=6.0.0
```

C. Kaynaklar

- Mikolov, T. et al. (2013). Efficient Estimation of Word Representations in Vector Space. *ICLR 2013*.
- Řehůřek, R., & Sojka, P. (2010). Software Framework for Topic Modelling with Large Corpora. *LREC 2010*.
- Gensim Documentation: <https://radimrehurek.com/gensim/>
- Scikit-learn Documentation: <https://scikit-learn.org>
- Streamlit Documentation: <https://docs.streamlit.io>