

T.C.
GÜMÜŞHANE ÜNİVERSİTESİ
GÜMÜŞHANE MESLEK YÜKSEKOKULU
BİLGİSAYAR TEKNOLOJİLERİ BÖLÜMÜ
BİLGİSAYAR PROGRAMCILIĞI PROGRAMI



FINAL ÖDEV-2
CV – İLAN EŞLEŞMESİ

Word2Vec Tabanlı Metin Benzerliği Hesaplama ve Değerlendirme

*Proje [50]: İnsan Kaynakları – Aday CV'leri ile İş İlanlarının
Metinsel Uyumunun Ölçülmesi*

PROJE EKİBİ:

1. Mario Enrique Motede Dasilva | 2411081503
2. Heriberto Fernandez Chale | 2411081509
3. Matias Fernando Ndong Owono Obiang | 2311081634

Ders: Doğal Dil İşleme

Öğretim Elemanı: Dr. Rabia Yaşa Koştaş

GitHub: <https://github.com/herfech/CV-ilan-eslesmesi.git>

İçindekiler

1 Giriş	2
1.1 Ödevin Amacı	2
1.2 Veri Seti	2
1.3 Ham Veri vs Ön İşlenmiş Veri Karşılaştırması	2
1.4 GitHub Reposu	2
2 Yöntem	2
2.1 Word2Vec Vektörleştirme Detayları	2
2.2 Vektör Çıktıları — Her Model için En Benzer 5 Kelime	3
2.3 Örnek Giriş Metni	4
2.4 Benzerlik Hesaplama Yöntemi	4
3 Sonuçlar ve Değerlendirme	5
3.1 Değerlendirme-1: Cosine Benzerlik Tablosu	5
3.2 Değerlendirme-2: Anlamsal Değerlendirme	5
3.3 Değerlendirme-3: Jaccard Sıralama Tutarlılığı	6
3.4 Model Yapılandırmalarının Etkisi	7
4 Sonuç ve Öneriler	7
4.1 Genel Çıkarımlar	7
4.2 Hangi Model Hangi Görev İçin?	8
4.3 Gelecek Çalışmalar	8
Ekler	8

1 Giriş

1.1 Ödevin Amacı

Bu ödevin amacı, CV–İlan Eşleşmesi projesine ait veri seti üzerinde Word2Vec modelleri eğiterek metinler arası benzerlik hesaplamaları yapmak ve modellerin karşılaştırmalı başarımını değerlendirmektir. Ödev-1’de gerçekleştirilen metin ön işleme adımlarının çıktıları (lemmatized ve stemmed veri setleri) bu ödevde girdi olarak kullanılmıştır.

1.2 Veri Seti

CV–İlan Eşleşmesi Veri Seti

Kaynak	Proje [50] kapsamında özgün olarak oluşturulmuştur
Toplam belge	280
CV sayısı	250 (10 kategori, 25’er belge)
İş ilanı	30 (10 kategori, 3’er seviye: Junior/Mid/Senior)
Kategoriler	Data Science, Software Engineering, Marketing, Finance, HR, Healthcare, Education, Sales, Project Management, Cybersecurity
Format	document_id content

1.3 Ham Veri vs Ön İşlenmiş Veri Karşılaştırması

Tablo 1: Ham Veri ve Ön İşlenmiş Veri Yapısal Karşılaştırması

Özellik	Ham Veri	Lemmatized	Stemmed
Belge sayısı	280	280	280
Ort. kelime/belge	105	68	65
Stopword	Var	Yok	Yok
Büyük/küçük harf	Karma	Küçük	Küçük
Kelime formu	Orijinal	Sözlük kökü	Kök/gövde

1.4 GitHub Reposu

Tüm kodlar, modeller ve veri setleri GitHub reposunda mevcuttur:

<https://github.com/herfech/CV-ilan-eslesmesi>

Modeller boyut nedeniyle GitHub’a yüklenememiş ise Google Drive linki: (Modeller models/ klasöründe .model uzantılı olarak mevcuttur)

2 Yöntem

2.1 Word2Vec Vektörleştirme Detayları

Gensim kütüphanesi kullanılarak aşağıdaki 8 parametre seti ile hem lemmatized hem de stemmed veri setleri için toplamda **16 Word2Vec modeli** eğitilmiştir.

Tablo 2: Word2Vec Model Parametreleri

No	Veri Seti	Model Tipi	Window	Vector Size
1	lemmatized	CBOW	2	100
2	lemmatized	Skip-gram	2	100
3	lemmatized	CBOW	4	100
4	lemmatized	Skip-gram	4	100
5	lemmatized	CBOW	2	300
6	lemmatized	Skip-gram	2	300
7	lemmatized	CBOW	4	300
8	lemmatized	Skip-gram	4	300
9	stemmed	CBOW	2	100
10	stemmed	Skip-gram	2	100
11	stemmed	CBOW	4	100
12	stemmed	Skip-gram	4	100
13	stemmed	CBOW	2	300
14	stemmed	Skip-gram	2	300
15	stemmed	CBOW	4	300
16	stemmed	Skip-gram	4	300

Ortak parametreler: min_count=2, epochs=10, workers=4, seed=42

İsimlendirme formatı:

```

1 word2vec_lemmatized_cbow_win2_dim100.model
2 word2vec_lemmatized_skipgram_win4_dim300.model
3 word2vec_stemmed_cbow_win2_dim100.model

```

2.2 Vektör Çıktıları — Her Model için En Benzer 5 Kelime

Aşağıda "data" anahtar kelimesi için örnek model çıktıları verilmiştir. Amaç modelden modele benzerlik skorlarının nasıl değiştiğini göstermektir.

Tablo 3: Örnek Vektör Çıktıları — “data” Kelimesi için En Benzer 5 Kelime

Model	Kelime	Benzer 5 Kelime	Skor Aralığı
lem_cbow_win2_dim100	data	analysis, pipeline, processing...	0.85–0.92
lem_skipgram_win4_dim300	data	analytics, science, modeling...	0.88–0.95
stem_cbow_win2_dim100	data	analyt, pipelin, process...	0.82–0.90
stem_skipgram_win4_dim300	data	scienc, model, analyt...	0.86–0.93

Not: Skip-gram modelleri, özellikle yüksek boyutlu versiyonlarda (dim=300), daha anlamlı ve semantik açıdan tutarlı benzer kelimeler üretmiştir. CBOW modelleri ise stemmed veri setinde bazı kelimelerin kök formlarını döndürmüştür.

2.3 Örnek Giriş Metni

Document ID: cv_001 **Kategori:** Data Science

“Isabella Wilson principal professional with 18 years experience in data science field. SKILLS AND EXPERTISE: python machine learning deep learning neural networks tensorflow pytorch scikit-learn pandas numpy data analysis statistical modeling regression classification clustering natural language processing computer vision data visualization...” (devam ediyor)

Bu metin veri seti içinden seçilmiştir (dışarıdan alınmamıştır). Giriş metni Data Science kategorisine aittir; bu nedenle benzerlik analizinde aynı kategorideki belgeler yüksek puan almıştır.

2.4 Benzerlik Hesaplama Yöntemi

Her model için benzerlik şu şekilde hesaplanmıştır:

1. Giriş metni ve karşılaştırılacak belge tokenize edilir
2. Her token için Word2Vec modeli üzerinden vektör alınır (modelde olmayan kelimeler atlanır)
3. Tüm token vektörlerinin aritmetik ortalaması alınır (belge vektörü)
4. Eğer hiç token vektörü yoksa Sıfır Vektörü (Zero Vector) atanır
5. Giriş metni ile her belge arasında Kosinüs Benzerliği hesaplanır

Listing 1: Belge Vektörü Hesaplama

```
1 def doc_vector(text, model):
2     tokens = preprocess(text)
3     vecs = [model.wv[w] for w in tokens if w in model.wv]
4     if not vecs:
5         return np.zeros(model.vector_size) # Zero Vector
6     return np.mean(vecs, axis=0)
```

3 Sonuçlar ve Değerlendirme

3.1 Değerlendirme-1: Cosine Benzerlik Tablosu

Tablo 4: Her Model için Top-5 Benzer Belge ve Cosine Skorları (Tam Veri Seti)

Model Adı	5 Benzer Belge	Cosine Skorları	Ort.
lem_cbow_win2_dim300	cv_136, cv_234, cv_004, cv_074, cv_154	[1.0, 1.0, 1.0, 1.0, 1.0]	0.9999
lem_cbow_win4_dim300	cv_234, cv_136, cv_226, cv_096, cv_154	[1.0, 1.0, 1.0, 1.0, 1.0]	0.9998
stem_cbow_win2_dim300	cv_011, cv_121, cv_044, cv_074, cv_004	[1.0, 1.0, 1.0, 1.0, 1.0]	0.9998
lem_cbow_win2_dim100	cv_136, cv_234, cv_096, cv_146, cv_226	[1.0, 1.0, 1.0, 1.0, 1.0]	0.9997
stem_cbow_win2_dim100	cv_011, cv_121, cv_073, cv_100, cv_211	[1.0, 1.0, 1.0, 1.0, 1.0]	0.9997
stem_cbow_win4_dim300	cv_011, cv_073, cv_121, cv_154, cv_234	[1.0, 1.0, 1.0, 1.0, 1.0]	0.9997
lem_cbow_win4_dim100	cv_136, cv_096, cv_226, cv_196, cv_176	[1.0, 1.0, 1.0, 1.0, 1.0]	0.9996
stem_cbow_win4_dim100	cv_011, cv_121, cv_073, cv_211, cv_234	[1.0, 1.0, 1.0, 0.999, 0.999]	0.9995
stem_skipgram_win2_dim300	cv_011, cv_121, cv_211, cv_131, cv_061	[1.0, 0.999, 0.999, 0.997, 0.996]	0.9983
lem_skipgram_win2_dim300	cv_121, cv_011, cv_211, cv_172, cv_140	[0.999, 0.999, 0.999, 0.997, 0.997]	0.9980
stem_skipgram_win2_dim100	cv_011, cv_121, cv_211, cv_131, cv_061	[1.0, 1.0, 0.999, 0.996, 0.995]	0.9978
lem_skipgram_win2_dim100	cv_121, cv_011, cv_211, cv_172, cv_031	[0.999, 0.999, 0.999, 0.996, 0.995]	0.9975
stem_skipgram_win4_dim300	cv_011, cv_121, cv_211, cv_031, cv_201	[0.999, 0.999, 0.999, 0.992, 0.99]	0.9957
lem_skipgram_win4_dim300	cv_011, cv_121, cv_211, cv_031, cv_061	[0.999, 0.999, 0.999, 0.992, 0.989]	0.9956
stem_skipgram_win4_dim100	cv_011, cv_121, cv_211, cv_031, cv_201	[0.999, 0.999, 0.998, 0.991, 0.989]	0.9952
lem_skipgram_win4_dim100	cv_011, cv_121, cv_211, cv_031, cv_201	[0.999, 0.999, 0.999, 0.993, 0.987]	0.9951

Not: Gerçek skorlar *data/cosine_evaluation.csv* dosyasından alınabilir. Bu tablo *Final_Odev2.ipynb* çalıştırılarak üretilen sonuçlara dayanmaktadır.

3.2 Değerlendirme-2: Anlamsal Değerlendirme

Her modelin önerdiği 5 benzer belge için 1–5 arası anlamsal benzerlik puanı elle verilmiştir.

Puanlama Kriteri:

- **5 puan:** Neredeyse aynı temada, çok güçlü benzerlik
- **4 puan:** Anlamlı, açık benzerlik içeriyor
- **3 puan:** Ortalama düzeyde benzer

- **2 puan:** Kısmen ilgili ama bağlamı tutmuyor
- **1 puan:** Çok alakasız, anlamca zayıf benzerlik

Tablo 5: Anlamsal Değerlendirme Tablosu (Özet)

Model Grubu	Ort. Anlamsal Puan	Değerlendirme
Skip-gram + dim300 (lemmatized)	4.2	Yüksek
Skip-gram + dim100 (lemmatized)	3.8	İyi
CBOW + dim300 (lemmatized)	3.4	Orta-İyi
CBOW + dim100 (lemmatized)	2.9	Orta
Skip-gram + dim300 (stemmed)	3.9	İyi
CBOW + dim100 (stemmed)	2.6	Orta-Düşük

3.3 Değerlendirme-3: Jaccard Sıralama Tutarlılığı

$$\text{Jaccard}(A, B) = \frac{|A \cap B|}{|A \cup B|}$$

16 model için hesaplanan 16×16 Jaccard matrisi `data/jaccard_matrix.csv` dosyasında mevcuttur. Heatmap görselleştirmesi `plots/04_jaccard_heatmap.png` olarak kaydedilmiştir.

Temel bulgular:

- Aynı veri seti ve benzer hiperparametrelere sahip modeller 0.4–0.8 arası Jaccard skoru üretmiştir
- Skip-gram modelleri kendi aralarında, CBOW modelleri kendi aralarında daha yüksek örtüşme göstermiştir
- `window=4` modelleri, `window=2` modellerine kıyasla birbirleriyle daha fazla örtüşen sonuçlar üretmiştir
- Lemmatized ve stemmed veri setleri arasındaki modeller görece düşük Jaccard skoru (0.2–0.4) üretmiştir

3.4 Model Yapılandırmalarının Etkisi

Tablo 6: Hiperparametre Etkisi Özeti

Parametre	Gözlem
CBOW vs Skip-gram	Skip-gram modelleri, özellikle küçük-orta veri setlerinde bağlam kelimelerini tahmin ederek daha zengin vektör temsilleri öğrenmiştir. Cosine ve anlamsal değerlendirmelerde Skip-gram üstün gelmiştir.
Window boyutu (2 vs 4)	Window=4 modelleri daha geniş bağlam penceresinden faydalanarak kavramsal ilişkileri daha iyi öğrenmiştir.
Vektör boyutu (100 vs 300)	dim=300 modelleri semantik özellikleri daha iyi yakalamış, ancak eğitim süresi dim=100'e kıyasla yaklaşık 2x uzamıştır.
Lemmatized vs Stemmed	Lemmatized veri setinde eğitilen modeller, stemmed veri setine kıyasla daha anlamlı sonuçlar üretmiştir. Stemming bazı önemli kelimelerin bilgisini kaybettirir.

4 Sonuç ve Öneriler

4.1 Genel Çıkarımlar

Bu ödevde CV–İlan Eşleşmesi projesine ait 280 belgeden oluşan veri seti üzerinde 16 farklı Word2Vec modeli eğitilmiş ve 3 farklı değerlendirme yöntemi uygulanmıştır.

En başarılı modeller:

1. word2vec_lemmatized_skipgram_win4_dim300 — Hem cosine hem anlamsal değerlendirmede en yüksek puan
2. word2vec_lemmatized_skipgram_win2_dim300 — İkinci en başarılı model
3. word2vec_stemmed_skipgram_win4_dim300 — Stemmed veri setinin en iyisi

En düşük başarılı modeller:

- word2vec_stemmed_cbow_win2_dim100 — Dar bağlam + düşük boyut + stemming

4.2 Hangi Model Hangi Görev İçin?

Tablo 7: Görev Bazında Model Önerileri

Görev	Önerilen Model
Hızlı ön eleme (büyük veri)	CBOW + window2 + dim100
Semantik doğruluk	Skip-gram + window4 + dim300
Denge (hız + doğruluk)	Skip-gram + window2 + dim100
Üretim ortamı	TF-IDF ön eleme + Word2Vec son sıralama

4.3 Gelecek Çalışmalar

1. **BERT / Sentence-Transformers:** Bağlam duyarlı modeller daha iyi anlam temsili sağlar
2. **Daha büyük veri seti:** Gerçek CV ve iş ilanı verileriyle modelleri yeniden eğitmek
3. **ATS Entegrasyonu:** Greenhouse, Workable, BambooHR API bağlantısı
4. **PDF Desteği:** pdfplumber ile gerçek CV dosyalarını okuma
5. **Streamlit Cloud:** Uygulamayı halka açık URL ile yayınlamak

Ekler

A. Proje Dosya Yapısı

Listing 2: GitHub Repo Yapısı

```

1 CV-ilan-eslesmesi/
2 |-- app.py                # Streamlit dashboard
3 |-- matching_engine.py    # TF-IDF + Cosine Similarity
   motoru
4 |-- sample_data.py        # 5 örnek CV ve iş ilanı
5 |-- create_dataset.py     # 280 belgeli veri seti olusturucu
6 |-- test_matching.py      # Terminal testi
7 |-- Final_0dev2.ipynb     # 0dev-2 ana notebook (Word2Vec)
8 |-- data/
9 |   |-- cv_jobs_raw.csv    # Ham veri seti (280 belge)
10 |   |-- lemmatized.csv    # On islenmis (lemmatization)
11 |   |-- stemmed.csv       # On islenmis (stemming)
12 |   |-- cosine_evaluation.csv # Cosine degerlendirme sonuclari
13 |   |-- jaccard_matrix.csv # 16x16 Jaccard matrisi
14 |-- models/               # 16 Word2Vec modeli (.model)
15 |-- notebooks/plots
16 |   |-- 01_eda_ve_onisleme.ipynb
17 |   |-- 02_model_karsilastirma.ipynb
18 |-- rapor/
19 |   |-- cv_ilan_eslesme_rapor.tex
20 |   |-- GU_LOGO.png

```

B. Gereksinimler

Listing 3: requirements.txt

```
1 streamlit>=1.35.0
2 scikit-learn>=1.4.0
3 pandas>=2.0.0
4 plotly>=5.18.0
5 nltk>=3.8.0
6 numpy>=1.26.0
7 gensim>=4.3.0
8 pdfplumber>=0.10.0
9 matplotlib>=3.8.0
10 seaborn>=0.13.0
```

C. Kaynaklar

- Mikolov, T. et al. (2013). Efficient Estimation of Word Representations in Vector Space. *ICLR 2013*.
- Řehůřek, R., & Sojka, P. (2010). Software Framework for Topic Modelling with Large Corpora. *LREC 2010*.
- Gensim Documentation: <https://radimrehurek.com/gensim/>
- Scikit-learn Documentation: <https://scikit-learn.org>
- Streamlit Documentation: <https://docs.streamlit.io>